

學號：B03705006 系級：資管三 姓名：侯舜元


1. 請簡明扼要地闡述你如何抽取模型的輸入特徵 (feature)

答：

在一筆(train_x,train_y)的 pair 之中，train_x 裡面包含每天隨機的連續九小時的 PM2.5 資料。train_y 第十小時資料為 answer。(每天隨機取 n 筆共取 240 天)

2. 請作圖比較不同訓練資料量對於 PM2.5 預測準確率的影響

答：



藍色水平線為平均誤差的值：5.715308372528903

原本是預想越大的訓練資料量，PM2.5 的預測會越準，但是圖上所顯示的不盡然如此。圖中可以看出，當訓練資料量大時，其誤差皆蠻接近平均的，而較小的資料量其誤差的分布的 variance 比較大。而在小的訓練量時，我推估因為 bias 的關係剛好蠻多組合都有較小的誤差。

3. 請比較不同複雜度的模型對於 PM2.5 預測準確率的影響

答：

一次式的模型 $y = b + \sum_{i=1}^9 w_i x_i$ (變數： b, w_1, \dots, w_9)

特徵值： x_1, x_2, \dots, x_9 ，為一連續九小時的 PM2.5 資料。

以此模型在 2500 筆訓練測資訓練出的最佳模型，其平均誤差為 5.798497729184221

二次式的模型 $y = b + \sum_{i=1}^9 w_i x_i + \sum_{i=10}^{18} w_i x_{i-9}^2$ (變數： b, w_1, \dots, w_{18})

特徵值： x_1, x_2, \dots, x_9 ，為一連續九小時的 PM2.5 資料。

以此模型在 2500 筆訓練測資訓練出的最佳模型，其平均誤差為 7.217467116729584

一次式的模型搭配取 PM2.5 和 PM10 為 feature

$$y = b + \sum_{i=1}^9 w_i x_i + \sum_{i=10}^{18} w_i x_{i-9}$$

(變數： b, w_1, \dots, w_{18})

特徵值： x_1, x_2, \dots, x_9 ，為一連續九小時的 PM2.5 資料， $x_{10}, x_{11}, \dots, x_{18}$ 為與 PM2.5 同時段的連續 PM10 資料。

以此模型在 2500 筆訓練測資訓練出的最佳模型，其平均誤差為 5.729103470087808

可以看出，越複雜的模型不見得有比較好的結果。最低的誤差為使用一次模型搭配 PM10，但 Kaggle 上最佳的結果 5.60939 為只使用 PM2.5 一次式模型。故推測有可能有 Overfitting 的情況發生。

4. 請討論正規化(regularization)對於 PM2.5 預測準確率的影響

答：

$$y = b + \sum_{i=1}^9 w_i x_i + \lambda \sum_{i=1}^9 w_i^2 \text{ (2500 筆資料, iteration 10000, learning rate 0.1)}$$

$\lambda = 0, \text{MRSE} = 5.82365$	$\lambda = 0.5, \text{MRSE} = 5.8347853$	$\lambda = 1, \text{MRSE} = 5.850734$
$\lambda = 5, \text{MRSE} = 6.022398$	$\lambda = 10, \text{MRSE} = 6.2203094$	$\lambda = 50, \text{MRSE} = 7.135542$

λ 值越高，MRSE 越高，正規化並無法提升準確率。

5. 在線性回歸問題中，假設有 N 筆訓練資料，每筆訓練資料的特徵 (feature) 為一向量 x^n ，其標註(label)為一存量 y^n ，模型參數為一向量 w (此處忽略偏權值 b)，則線性回歸的損失函數(loss function)為 $\sum_{n=1}^N (y^n - w \cdot x^n)^2$ 。若將所有訓練資料的特徵值以矩陣 $X = [x^1 \ x^2 \ \dots \ x^N]$ 表示，所有訓練資料的標註以向量 $y = [y^1 \ y^2 \ \dots \ y^N]^T$ 表示，請以 X 和 y 表示可以最小化損失函數的向量 w 。

答：

$$\begin{aligned}\hat{w} &= \operatorname{argmin}_w S(w) \\ S(w) &= |y - Xw|^2 \\ (X^T X) \hat{w} &= X^T y\end{aligned}$$

$$\text{最小化損失函數的向量 } \hat{w} = (X^T X)^{-1} X^T y$$